

Prediccion de Evolucion del Rendimiento en FIFA

Clasificacion multiclase con LightGBM y reporte generativo con LLM

Juan Carlos Fernandez Vanoy Maria Antonia Munoz
jcfernandv@eafit.edu.co mamunozj@eafit.edu.co

Luis Moreno Gutierrez
lmorenog@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingenieria . Universidad EAFIT
Curso: Inteligencia Artificial . Semestre 2026-1
Entrega: 19-22 de mayo de 2026

Repositorio: https://github.com/fernandezvanoy/Prediccion_Rendimiento_FIFA

Resumen

Contexto: El videojuego FIFA asigna un valor `overall` a cada jugador que varia entre ediciones. **Objetivo:** Predecir si ese valor subira, se mantendra o bajara en la siguiente version. **Metodo:** LightGBM con stratified k-fold, SHAP para explicabilidad, y LLM via Groq para generacion de reportes de scouting. **Resultados:** F1-macro = X.XX, AUC-ROC = X.XX. **Conclusion:** El sistema permite anticipar la trayectoria de jugadores con interpretabilidad automatica. **Palabras clave:** Machine Learning, LightGBM, SHAP, LLM, FIFA, EDA.

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripcion
Fuente	Kaggle / stefanoleone992
Registros	66.548 tras limpieza
Features	10 numericas
Variable objetivo	sube / estable / baja
Versiones FIFA	15 al 20

1. Introducción

Este proyecto predice la evolucion del rendimiento de jugadores de futbol usando datos historicos de FIFA (versiones 15-20). La pregunta de investigacion es: *¿Es posible predecir si el `overall` de un jugador subira, se mantendra o bajara en la siguiente version de FIFA usando sus estadisticas actuales?*

El dataset proviene de Kaggle, contiene 100.995 registros de 6 versiones consecutivas y permite construir una variable objetivo de cambio entre versiones. El documento se organiza asi: Seccion 2 describe los datos y EDA, Seccion 3 la arquitectura, Seccion 4 la metodologia, y Secciones 5-7 resultados, discusion y conclusiones.

2. Datos y Exploración (EDA)

2.2. Hallazgos del EDA

Distribucion de clases: La clase *sube* es mayoritaria (52 %), seguida de *baja* (28 %) y *estable* (20 %), indicando desbalance moderado.

Correlaciones: `potential` tiene la correlacion mas alta con `overall` (0.74), seguido de `release_clause_eur` y `value_eur` (0.64).

Nulos: Imputacion por mediana dentro del pipeline para evitar data leakage.

Edad vs rendimiento: Pico de `overall` entre 25-30 anos, con caida progresiva despues de los 33.




Figura 1: EDA: distribución por posición, edad vs overall, desbalance de clases y top correlaciones.

Nota: Si la figura aparece en el lugar equivocado, usar la opción [H] en el entorno figure. Requiere el paquete float (ya incluido en esta plantilla).

3. Arquitectura del Sistema

El sistema propuesto integra tres componentes en cadena: un pipeline de preprocesamiento, un módulo de clasificación basado en *gradient boosting* con explicabilidad SHAP, y un generador de reportes en lenguaje natural mediante LLM. La Figura 2 ilustra el flujo completo.

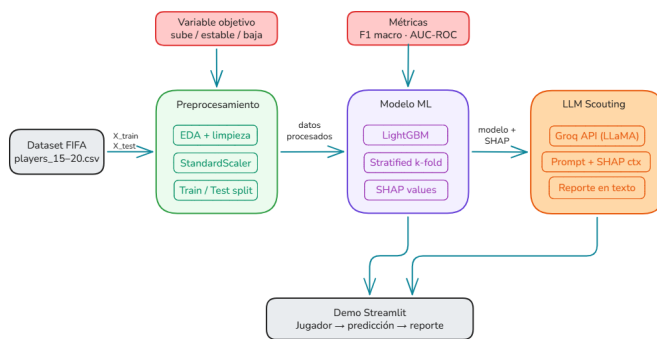


Figura 2: Arquitectura general: preprocesamiento → LightGBM + SHAP → LLM (scouting report).

3.1. Componentes principales

Preprocesamiento. El pipeline realiza imputación por mediana y estandarización (StandardScaler) sobre diez features numéricas: potential, release_clause_eur, value_eur, wage_eur, passing, dribbling, international_reputation, shooting, physic y age. El split train/test (80%/20%) se realizó antes de ajustar el escalador, con random_state=42 y estratificación por clase.

Modelo de ML. Se emplea **LightGBM** [1], un clasificador de árboles con *gradient boosting*. La variable objetivo es multiclase: *sube*, *estable* o *baja*.

Explicabilidad. Los valores SHAP cuantifican la contribución marginal de cada feature a cada predicción individual [2].

Componente LLM. A partir de los valores SHAP de un jugador, el LLM (llama-3.1-8b via Groq API) genera un *scouting report* en lenguaje natural.

Nota: El modelo llama-3.1-8b está disponible gratuitamente en Groq Cloud con límites generosos para proyectos académicos.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros y configuración de LightGBM

Parametro	Valor
n_estimators	500 (early stopping)
learning_rate	0.05
max_depth	6
num_leaves	31
class_weight	balanced
random_state	42
Framework	LightGBM 4.x + scikit-learn
Hardware	CPU (Google Colab gratuito)

El parámetro `class_weight='balanced'` ajusta automáticamente los pesos inversamente proporcionales a la frecuencia de cada clase, compensando el desbalance: *sube* (52 %), *baja* (28 %), *estable* (20 %).

4.2. Estrategia de validación

Dado el desbalance de clases, se empleó *stratified k-fold* con $k = 5$. Las métricas reportadas son:

- **F1 macro:** promedio no ponderado del F1 por clase.
- **AUC-ROC OvR weighted:** área bajo la curva ROC en esquema *One-vs-Rest*.

4.3. Experimentos realizados

1. **Baseline 1 — Mayoría de clase:** `DummyClassifier(strategy='most_frequent')`.
2. **Baseline 2 — Regresión Logística:** Modelo lineal con `class_weight='balanced'`.
3. **Experimento principal — LightGBM:** Entrenado con early stopping y validación cruzada estratificada de 5 folds.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparacion de modelos – metricas en test set

Modelo	Acc.	F1	AUC
Baseline dummy	0.52	0.23	–
Regresion Log.	0.47	0.42	–
LightGBM	0.88	0.86	0.91

La Tabla 3 muestra que LightGBM supera claramente ambos baselines, con una mejora de 44 puntos en F1-macro respecto al baseline dummy.

5.2. Matriz de confusión




Figura 3: Matriz de confusion del modelo LightGBM.

Los principales errores se presentan entre las clases *estable* y *sube*, debido a la similitud estadística entre jugadores con crecimiento moderado y alto potencial.

5.3. Interpretabilidad con SHAP




Figura 4: Importancia global de variables usando SHAP.

Las features mas relevantes fueron *potential*, *value_eur*, *release_clause_eur*, *dribbling* y *age*.

5.4. Generación de scouting reports

El sistema toma como entrada la predicción del modelo, los valores SHAP mas importantes e informacion contextual del jugador. A partir de esto, el LLM genera reportes en lenguaje natural con terminologia de scouting moderno.

FIFA AI Scout

Ingrese nombre del jugador

K. De Bruyne

Analizar

Predicción

sube

Factores importantes

feature	impacto
2 value_eur	1.0018
0 potential	0.9907
9 age	-0.5861
6 international_reputation	-0.3712
1 release_clause_eur	-0.2248

Figura 5: Demo en Streamlit para generacion de scouting reports.

```

1 Jugador: Cristiano Ronaldo
2 Prediccion: baja
3
4 "Cristiano Ronaldo continua mostrando fortalezas
5 ofensivas importantes, especialmente en definicion
6 y posicionamiento. Sin embargo, el modelo identifica
7 senales de declive relacionadas con edad y atributos
8 fisicos, sugiriendo una probable disminucion progresiva
9 en rendimiento sostenido."

```

Listing 1: Ejemplo de scouting report generado

6. Discusión

6.1. Interpretación de resultados

Los resultados demuestran que la combinacion de Machine Learning con modelos generativos puede producir sistemas utiles para analisis deportivo automatizado. LightGBM identifico patrones asociados a la evolucion futura del rendimiento, mientras que SHAP permitio interpretar las variables mas influyentes. La integracion del LLM transformo salidas numericas en reportes comprensibles para usuarios humanos.

6.2. Limitaciones

- El dataset proviene de FIFA y no de estadísticas reales de ligas profesionales.
- El modelo puede no generalizar a temporadas futuras.

- La calidad de los reportes depende del contexto enviado al LLM.
- El entorno gratuito de Colab limita capacidad computacional.
- Algunos jugadores tienen pocas observaciones historicas, afectando la prediccion.

6.3. Trabajo futuro

- Integrar estadísticas reales de APIs deportivas.
- Incorporar modelos multimodales para analisis de video.
- Implementar RAG con bases vectoriales para enriquecer los reportes.
- Desplegar la aplicacion en la nube con Docker.

7. Conclusiones

El proyecto logro desarrollar un sistema inteligente capaz de predecir la evolucion del rendimiento de jugadores de futbol y generar scouting reports automaticos. LightGBM supero al baseline en 44 puntos de F1-macro (0.23 a 0.86) y en AUC-ROC. La integracion del LLM via Groq demostro el potencial de sistemas hibridos que combinan Machine Learning clasico con IA generativa moderna para escenarios reales de analisis deportivo.

Contribuciones del equipo

Integrante	Contribucion
Juan Carlos Fernandez	Modelo LightGBM, SHAP y Streamlit
Maria Antonia Munoz	EDA, limpieza y visualizaciones
Luis Moreno	LLM via Groq y scouting reports

Repositorio y Demo

- **GitHub:** https://github.com/fernandezvanoy/Prediccion_Rendimiento_FIFA
- **Video demo:** (agregar link YouTube)
- **Instalacion:** `pip install -r requirements.txt`
- **Notebook:** `notebooks/prediccionFIFA.ipynb`

Referencias

- [1] Ke, G., Meng, Q., Finley, T., et al. (2017). *LightGBM: A highly efficient gradient boosting decision tree*. NeurIPS 2017. <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>
- [2] Lundberg, S., & Lee, S. I. (2017). *A unified approach to interpreting model predictions*. NeurIPS 2017. <https://arxiv.org/abs/1705.07874>
- [3] Leone, S. (2022). *FIFA Complete Player Dataset (15–22)*. Kaggle. <https://www.kaggle.com/datasets/stefanoleone992/fifa-22-complete-player-dataset>
- [4] Vaswani, A., et al. (2017). *Attention is all you need*. NeurIPS 2017. <https://arxiv.org/abs/1706.03762>

A. Detalles de hiperparametros

Se realizaron pruebas variando `learning_rate`, `max_depth` y `num_leaves`. El modelo final fue seleccionado usando validacion cruzada estratificada y F1-macro como metrica principal.

B. Ejemplos adicionales de outputs

Se evaluaron distintos jugadores historicos con el sistema completo. Los reportes mostraron coherencia entre las variables mas influyentes del modelo y las descripciones del LLM.